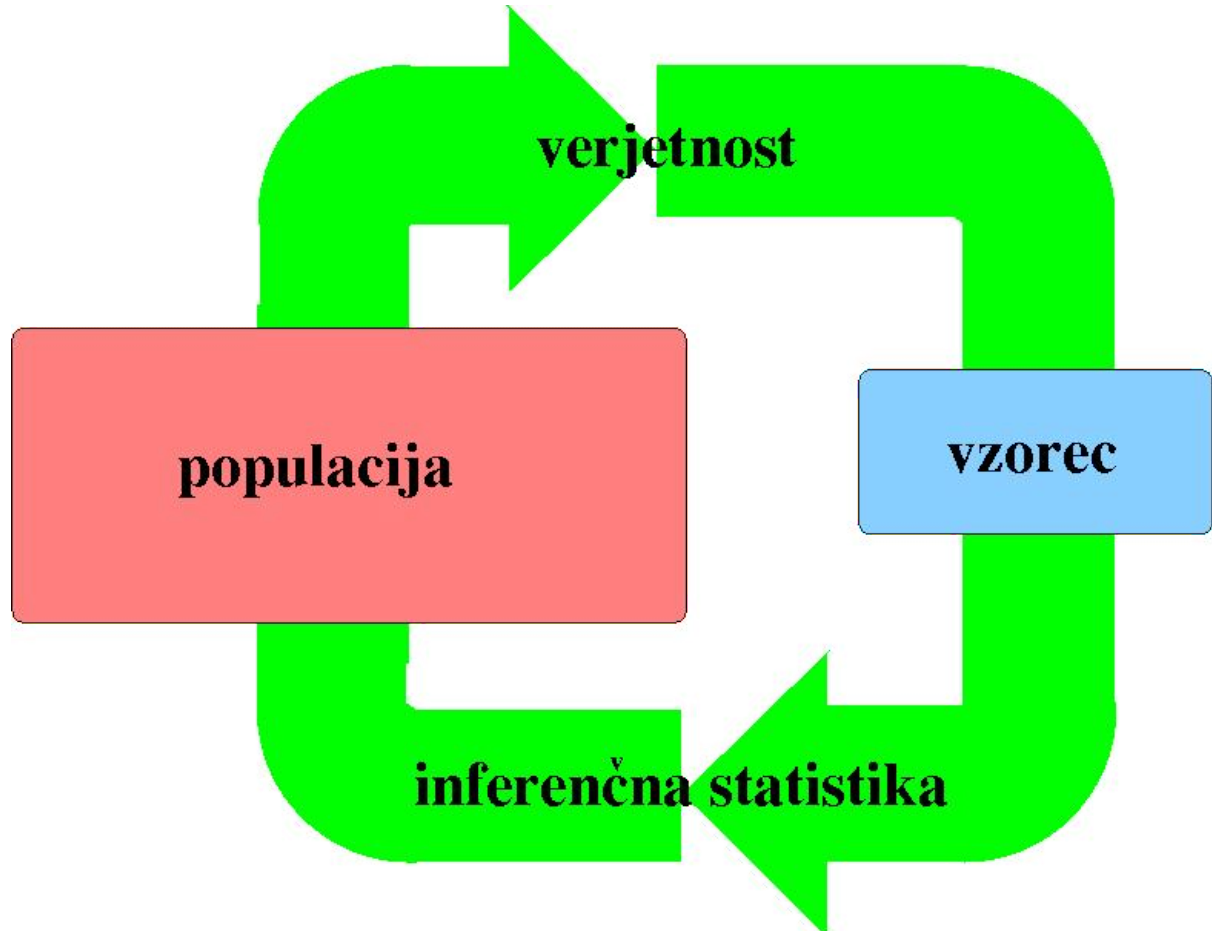


## OSNOVE VERJETNOSTI IN STATISTIKE

(Predznanje): **Osnove kombinatorike** (sami oz. na vajah ponovite pravilo vsote, pravilo produkta, permutacije, permutacije s ponavljanjem, kombinacije, binomski izrek in Pascalov trikotnik).


(1. poglavje) **Uvod**: Igre na srečo, kaj je statistika.

- Predstavitev predmeta in ekipe
- Zakaj obravnavamo verjetnost in statistiko hkrati?




(10. poglavje) **Opisna statistika**

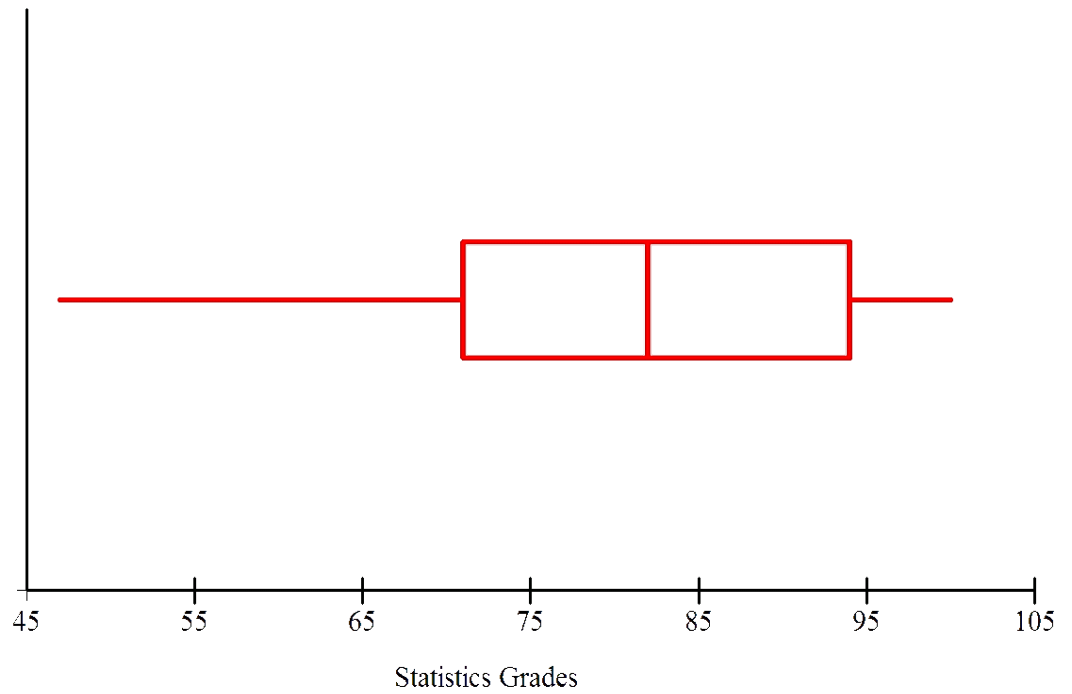
- (10.1) Vrste spremenljivk oziroma podatkov
- (10.2) Grafična predstavitev kvantitativnih podatkov: histogrami




- (10.3) Mere za lokacijo in razpršenost (srednje vrednosti - modus/mediana/povprečje), razpon,




- Centili/kvartili, škatla z brki



- 
- povprečje in druge (A.8) sredine dveh nenegativnih števil (od najmanjše do največje): kvadratna, aritmetična=povprečje, geometrijska, harmonična;



- 
- S potenčno sredino nenegativnih števil  $\backslash(k\backslash)$ -te stopnje lahko definiramo za
  - $\backslash(k=1\backslash)$  povprečje, ki mu pravimo tudi aritmetična sredina,
  - $\backslash(k=2\backslash)$  kvadratno sredino,
  - $\backslash(k=-1\backslash)$  harmonično srednino ter
  - v limiti, ko gre  $\backslash(k\backslash \rightarrow 0\backslash)$ , celo geometrijsko sredino
- (še vedno velja ista razvrstitev, katerikoli pa sta enaki natanko tedaj, ko so števila enaka)
- Varianca/disperzija/razperšenost, tj. kvadrat standardnega odklona (ki je kvadratna sredina vseh odklonov)
- Zvonasta oblika in empirična pravila (npr. 68-95-99.7), mere oblike
- Momenti, odklon in empirična pravila povezana z porazdelitvijo (ali podatki) zvonaste oblike



(10.4) Standardizacija ( $z = (x - m)/s$ ), odštevanje premakne izhodišče koordinatnega sistema v desno oz. os  $x$  v levo za  $m$ , deljanje pa predstavlja razteg oz. skrajšitev - odvisno od tega ali je količina  $s$  manjša ali večja od 1)

(2. poglavje) **Poskusi, dogodki in definicija verjetnosti:**

- Osnovni pojmi (gotov in nemogoč dogodek)
- Računanje z dogodki: je način dogodka, vsota in produkt dveh dogodkov, nasproten dogodek, (v zapiskih si lahko ogledate še matematično strukturo, ki ji pravimo [grupa](#))
- Popoln sistem dogodkov (najenostavnejši primer: črno-beli svet - [naloga o miški](#)).
- Statistična, klasična in geometrijska definicija verjetnosti
- Osnovne lastnosti verjetnosti (ne pozabite tudi na zakon vključitve in izključitve)  $P(A+B) = P(A) + P(B) - P(AB)$  za poljubna dogodka  $A$  in  $B$
- Vsota (unija) in produkt (preseka) treh in več dogodkov
- (2.5)\* Aksiomi Kolmogorova

(3. poglavje) **Pogojna verjetnost:**

- (3.1) Avto in dve kozi (Monty Hall problem)
- (3.2) Definicija (praktično enaka običajni verjetnosti, le seznamu pogojev za veljavnost poskusa dodamo, da se mora zgoditi še dogodek  $B$ )
- Formula za pogojno verjetnost (ekvivalentna relaciji  $P(B)P(A/B) = P(AB)$ ) seveda le če verjetnost  $P(B) \neq 0$ ,
- Kontingenčna tabela
- Neodvisnost dogodkov (dveh  $P(AB) = P(A)P(B)$ ) ali več
- Grafični pristop k pogojni verjetnosti in diagram dogodkov
- Naloga o nalezljivi bolezni (našli smo način z uporabo "dvojne" relacije  $P(B)P(A/B) = P(AB) = P(A)P(B/A)$  za poljubna dogodka  $A$  in  $B$ ) ter seveda prve relacije (pa ne pozabite na relacijo "marmornega kolača":  $P(B) = P(AB) + P(\bar{A}B)$  (mi ji bomo rekli formula za totalno verjetnost), kjer smo za popoln sistem dogodkov vzeli  $\{A, \bar{A}\}$  - vse skupaj smo morali formulo za pogojno verjetnost uporabiti trikrat).
- Naloga o nalezljivi bolezni (tudi grafična predstavitev reševanja - je nekoliko bolj urejena).
- (3.3) Obrazec za popolno verjetnost (razbitje - posplošitev marmornega kolača) in
- Večstopenjski poskusi in Bayesov obrazec, ki da odgovor na nalogo o nalezljivi bolezni v enem koraku.

(4. poglavje) **Bernoullijevo zaporedje neodvisnih poskusov.**

- (4.1) Računanje  $P_i(k)$ .
- (4.2) Usojena krivulja v Pascalovem trikotniku.
- (A.6) Stirlingova formula, (A.5) Število  $e$
- Študija oblike histograma, ki ga dobimo iz  $n$ -te vrstice Pascalovega trikotnika (A.6)
- Usojena krivulja: 'višina' kvadratov  $1 \times 1$  pomnožimo s kvocientom  $1/\sqrt{n}$ , širino pa s kvocientom  $1/\sqrt{n}$ , kar pomeni, da je površina celotnega histograma, ki ga sestavljajo novi pravokotniki, enaka 1, višina pa gre proti  $1/\sqrt{2\pi}$ . S katero funkcijo opišemo obliko tako dobljenega histograma (za dovolj velike  $n$ )?
- Histogram je simetričen glede na sredino - pri  $n/2$ , iz konkavne v konveksno ali obratno preide pri  $\frac{n}{2} \pm \sqrt{n}$  tako da vpeljemo standardizacijo  $x = \frac{k - (n/2)}{\sqrt{n/2}}$  in z nekaj matematičnega truda dobimo formulo za normalno krivuljo  $\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$
- De Moivreov točkovni obrazec (za  $p = 1/2$ ) ter njegovo posplošitev Laplaceov točkovni obrazec (za vrednosti  $p$ , ki so blizu  $1/2$ ):  $P_n(k) \approx \frac{1}{\sqrt{2\pi npq}} e^{-(k - np)^2 / 2npq}$

Zanimivost: Ste vedeli, da se da vseh pet najpomembnejših števil:

- 0 (enota za seštevanje oz. nevtralni element),
- 1 (enota za množenje),
- $\pi$  (razmerje med premerom in obsegom kroga, oz. med ploščino enotskega kroga in enotskega kvadrata, je iracionalno število  $3.14\dots$ ),
- $i$  (imaginarna enota),

- $e$  (slednje imenujemo tudi Eulerjeva konstanta oz. osnova naravnega logaritma in je enako  $\lim_{n \rightarrow \infty} (1 + \frac{1}{n})^n$ ), je tudi irracionalno število (2.71...)

•

povezati v eno samo zvezo na naslednji način  $e^{i\pi} + 1 = 0$ ? Zares neverjetna zveza (ki ji pravimo [Eulerjeva identiteta](#)).

#### (5. poglavje) Slučajne spremenljivke in porazdelitve:

- Porazdelitvena funkcija in njene lastnosti
- (5.1) diskretne slučajne spremenljivke: verjetnostna tabela, indikatorska slučajna spremenljivka
- Pričakovana vrednost slučajne spremenljivke  $\langle X \rangle$  (kot uteženo povprečje):  $\mu = E(X)$  ( $\mu$  glavna junakinja našega predmeta)
- Pričakovana vrednost za binomsko porazdelitev  $B(n, p)$  je  $np$  (privzamemo aditivnost  $E(X+Y) = E(X) + E(Y)$ ) in jo predstavimo kot vsoto indikatorskih slučajnih spremenljivk, ki imajo pričakovano vrednost  $p$
- Poissonova porazdelitev in povezava z binomsko porazdelitvijo, preko pričakovane vrednosti  $\lambda = np$ : Poissonov točkovni obrazec (za velike  $n$  in majhne vrednosti  $p$ ):  $P_n(k) \approx \frac{(np)^k}{k!} e^{-np} = \frac{\lambda^k}{k!} e^{-\lambda}$
- Pascalova porazdelitev (poseben primer - geometrijska porazdelitev,  $G(p)$ ), s pričakovano vrednostjo  $1/p$
- Geometrijska porazdelitev na praktičnem primeru - zbiranje kuponov (angl. coupon collector's problem ter occupancy problem, v literaturi se omenja tudi povezava s quality control) - zopet smo uporabili aditivno lastnost pričakovane vrednosti
- Hipergeometrijska porazdelitev (ima tri parametre)
- (5.2) Ponovitev: integrali (štetje kvadratkov ali preko prostornine vode)
- (5.3) Zvezne slučajne spremenljivke (gostota verjetnosti).
- Enakomerna porazdelitev zvezne slučajne spremenljivke na intervalu  $[a, b]$ ,  $\forall a \leq b$ , oznaka  $\mathcal{U}(a, b)$  (angl. uniform)
- Normalna ali Gaussova porazdelitev  $N(\mu, \sigma)$ , kjer je prvi parameter enak pričakovani vrednosti, drugi pa standardnemu odklonu (katerih pomena že poznamo)
- Standardna normalna porazdelitev, funkcija napake
- Laplaceov intervalski obrazec (raba: binomska porazdelitev  $B(n, p)$  je za velike  $n$  in  $p$  blizu  $1/2$  dobro aproksimirana z normalno porazdelitvijo  $N(np, \sqrt{np(1-p)})$ ).
- Bernoullijev zakon velikih števil, primer uporabe in dokaz
- Porazdelitev Poissonovega toka - eksponentna,
- Funkcija Gama (označimo jo z  $\Gamma(x)$ , potem je  $\Gamma(1) = 1$ ), zadovoljuje rekurzivno zvezo torej je  $\Gamma(x) = (x-1)\Gamma(x-1)$ , torej je  $\Gamma(n) = (n-1)!$  za naravno število  $n$ , kar pomeni, da je dovolj, da poznamo njene vrednosti npr. na intervalu  $(0, 1)$
- Hi-kvadrat porazdelitev

#### (6. poglavje) Slučajni vektorji in neodvisnost slučajnih spremenljivk:

- Definicije
- Robna porazdelitvena funkcija
- Diskretne večrazsežne porazdelitve, stopničasta ploskev
- (6.1) Polinomska porazdelitev
- Dvojni integral predstavlja prostornino pod ploskvijo: ponazorimo jo lahko z rjuho, ki jo v vsaki točki ravnine dvignemo na določeno višino, le-to predpisuje vrednost  $z = p(x, y)$  (če smo prej šteli kvadratke, moramo sedaj šteti kocke).
- Kako na grobo oceniti število kock na sliki (z običajnim štetjem ali z integriranjem)?
- (6.2) Intermezzo: ponovitev dvojnih in dvakratnih integralov
- (6.3) Zvezne večrazsežne porazdelitve
- Robni verjetnostni gostoti
- Primer
- Večrazsežna normalna porazdelitev
- Neodvisnost slučajnih spremenljivk

#### (7. poglavje) Funkcije slučajnih spremenljivk in vektorjev

- (7.1) Funkcije slučajnih spremenljivk
- (7.2) Funkcije in neodvisnost (funkcije slučajnih vektorjev, vsota slučajnih spremenljivk, konvolucija, primeri slučajnih spremenljivk, ki si porazdeljene normalno ali pa po hi-kvadrat)
- (7.3)\* Funkcije slučajnih vektorjev (Jaccobijevo determinanto in primer s polarnimi koordinatami lahko predelate samo, če vas zanima in želite pridobiti več izkušenj)
- (7.4) Pogojne porazdelitve (pogojna porazdelitvena funkcija,
- Pogojna verjetnostna funkcija
- Pogojna gostota (v primeru 2-razsežne normalne porazdelitve dobimo enorazsežno normalno porazdelitev)

#### (8. poglavje) **Momenti in kovarianca:**

- (8.1) Matematično upanje (pričakovana vrednost - njena povezava s povprečjem, kdaj obstaja
- Slučajna spremenljivka, ki ima Cauchyjevo porazdelitev nima mat. upanja
- Pričakovana vrednost vsote dveh slučajnih spremenljivk homogenost (linearen funkcional)
- Študija na primeru binomske porazdelitve,
- Linearnost (raba: pričakovana vrednost populacije  $\mu$  je enaka pričakovani vrednosti vzorčnega povprečja)
- Matematično upanje produkta in koreliranost
- (A.9) Cauchyjeva neenakost
- (8.2) Disperzija (definicija in lastnosti)
- (8.3) Standardizacija spremenljivke
- (8.4) Kovarianca (definicija, lastnosti, korelacijski koeficient)

#### Uvod v CLI (metanje dveh/treh kock)

- Parametri populacije: pričakovana vrednost ( $\mu$ ), odklon ( $\sigma$ ), delež ( $\pi$ ), parameter, ki povezuje dve populaciji - korelacijski koeficient ( $\rho$ ).
- Na vzorcu: vzorčno povprečje  $\bar{x}$ , vzorčni odklon  $s$ , vzorčni delež  $p$ .
- Slučajne spremenljivke  $(X_1, X_2, \dots, X_n)$  spremljajo dogajanje na vzorcu  $(x_1, x_2, \dots, x_n)$ , ki mora biti izbran naključno in neodvisno (to pomeni, da so te spremenljivke paroma neodvisne),  $(X)$  prečna pa označuje njihovo povprečje in je tudi slučajna spremenljivka.
- (8.5) Pogojno matematično upanje (regresijska funkcija)
- Kovariančna matrika
- (8.6) Višji momenti (začetni moment, centralni moment, asimetričnost, sploščenost, kvantili, mediana, kvantili, kvartilni razmik)

#### (9. poglavje) **Karakteristične funkcije in limitni izreki:**

- (9.1)\* Karakteristična funkcija
- (9.2)\* Limitni izreki (verjetnostno konvergira, skoraj gotovo konvergira)
- Preverili, da povprečje neodvisnih slučajnih spremenljivk  $(X_1, X_2, \dots, X_n)$ , ki so porazdeljene normalno, limitira k slučajni spremenljivki, ki je tudi normalna
- Če imajo vse slučajne spremenljivke  $(X_i)$  enak začetni moment  $(z_1)$ , potem ima tak moment tudi slučajna spremenljivka, ki predstavlja njihovo povprečje, medtem, ko gre (pada) drugi centralni moment proti 0 z naraščujočim  $(n)$
- (9.2)\* Šibki in krepki zakon velikih števil
- (9.3) Centralni limitni izrek (CLI)
- Čebiševa neenakost (z dokazom za zvezne slučajne spremenljivke) (lahko bi navedli tudi nekaj njenih posledic: izreka Markova in Čebiševa ter Bernoullijev zakon velikih števil)

#### Uporaba verjetnosti:

- Zamenjalna šifra (premešalka)
- Indeks ujemanja
- Izziv iz 2. svetovne vojne
- Paradoks rojstnih dnevo (v poljubni skupini 23ih ljudi je verjetnost, da imata vsaj dva skupni rojstni dan večja od  $1/2$ )
- Raba v kriptografiji (zgoščevalne funkcije, DLP)

- Raba v teoriji kodiranja (kode za odpravljanje napak: ponavljanje in večinsko pravilo, Hammingova koda - štirim bitom dodamo tri kontrolne in pokažemo, da lahko odpravimo eno napako, glavni mejniki teorije kodiranja)
- Ramseyeva teorija (popoln nered je nemogoč, vsaka dovolj velika struktura vsebuje urejeno podstrukturo, SIM igra, zgornje in spodnje meje za Ramseyjeva števila,...)
- V praksi pogosto potrebujemo učinkovito računanje v kolobarju ostankov pri deljenju z naravnim številom  $\backslash(n\backslash)$ , tj.  $\backslash(Z_n=\{0,1,\dots,n-1\}\backslash)$  in operacijama  $+$ ,  $*$  mod  $\backslash(n\backslash)$ 
  - Deljenje dosežemo z reševanjem linearne Diophantske enačbe  $\backslash(ax+by=c\backslash)$
  - Z Evklidovim algoritmom (EA) poiščemo  $\backslash(D(a,b)\backslash)$ , ki mora deliti  $\backslash(c\backslash)$  (to pa ni samo zadosten, pač pa tudi potreben pogoj za obstoj rešitev). Pri tem za naravni števili  $\backslash(a\backslash)$ ,  $\backslash(b\backslash)$  ( $\backslash(a\geq b\backslash)$ ), iščemo celi števili  $\backslash(q\backslash)$  in  $\backslash(r\backslash)$ , za kateri velja  $\backslash(a=qb+r\backslash)$  in  $\backslash(0\leq r<b\backslash)$ .
  - Iskanje kvocienta  $\backslash(q\backslash)$  je računsko zamudna operacija (z njim pa je lahko izračunati ostanek  $\backslash(r=a-bq\backslash)$ ), zato naključno izbiramo pare  $\backslash(a,b\backslash)$ , ki so manjši od fiksnega naravnega števila  $\backslash(M\backslash)$ .
  - Slučajna spremenljivka  $\backslash(Q\backslash)$  sledi vrednost kvocienta  $\backslash(q\backslash)$ .
  - Zanima nas njena porazdelitev, tj. verjetnosti
    - $\backslash(P(Q=1)\backslash)$ ,
    - $\backslash(P(Q=2)\backslash)$ ,
    - $\backslash(P(Q=3)\backslash)$ ,
    - ...,
  - ki jih brez težav izračunamo z geometrijskim pristopom:  $\backslash(P(Q=m)=1/(m(m+1))\backslash)$  oziroma
    - $\backslash(P(Q=1)=1/2\backslash)$ ,
    - $\backslash(P(Q=2)=1/6\backslash)$ ,
    - $\backslash(P(Q=3)=1/12\backslash)$ ,
    - ...
  - To pomeni, da se izplača izračunati  $\backslash(a-b\backslash)$  in preveriti, če je dobljena razlika manjša od  $\backslash(b\backslash)$ ,... (v polovici primerov bo).

(10. poglavje) **Opisna statistika:** ponovitev in standardizacija.

- CLI za delež

(11. poglavje) **Vzorčenje:**

- Ponovitev [CLI in njegova zgodba pri vzorčenju](#)
- hitrost centralne tendence pri CLI
- (11.3) Porazdelitev vzorčnih povprečij
- (11.4) Vzorčna statistika:
  - (A) vzorčno povprečje
  - (B) vzorčna disperzija
- Ponovitev variante CLI-ja za vzorčno disperzijo
- (11.5) Nove porazdelitve (Studentova, Fisherjeva)
- (11.6) Cenilke: osnovni pojmi, točkovne cenilke
- (11.6) Cenilke - simetrične funkcije/formule s katerimi iz meritev vzorca ocenimo določen parameter populacije (doslednost, nepristranskost)
- metoda momentov in metoda največjega verjetja;
- Cenilka  $\backslash(C_n\backslash)$  parametra  $\zeta$  je nepristranska, če je  $\backslash(E(C_n)=\zeta\backslash)$  (za vsak  $\backslash(n\backslash)$ )
- (11.7) Vzorčna statistika (nadaljevanje): (C) Vzorčne aritmetične sredine (nas ima res večina zelo podobne sposobnosti?)

CLI za delež,

- (D) Vzorčni deleži
- (E) Razlika vzorčnih aritmetičnih sredin
- (F) Razlika vzorčnih deležev

Na grafično nazoren način si [oglejte  \$\backslash\(z\backslash\)\$ -vrednosti](#), ki predstavljajo (s procenti od 1):

1. "0 to z" funkcijo napake  $\backslash(\Phi(z)\backslash)$ ,



2. "Up to z" porazdelitveno funkcijo  $\Phi(z)$  (oz.  $\Phi(x_p)$ ) je kvantil  $\Phi(p)$ -tega reda, kadar je  $\Phi(x_p)=p$ ) in
3. "z onwards" polovico tveganja, tj.  $P(Z \geq z_{\alpha/2}) = \alpha/2 = P(Z \leq -z_{\alpha/2})$

(da boste potem lažje uporabljali tabele za  $\Phi(N(0,1))$  na kolokviju/izpitu)

Pregledna predstavitev vseh izrekov tipa CLI, ki smo jih spoznali doslej (CLI za pričakovano vrednosti, za odklon, za delež in za razlike pričakovanih vrednosti ter deležev).

(12. poglavje) **Intervali zaupanja:**

- (12.1) Pomen stopnje tveganja pri intervalih zaupanja;
- (12.2) Intervalno ocenjevanje parametrov za:
  - pričakovano vrednost
  - delež
  - odklon
  - razliko pričakovanih vrednosti (tudi v primeru ujemajočih se parov), deležev in za
  - kvocient odklonov
- (12.3) Izbira velikosti vzorca

(13. poglavje) **Preverjanje domnev:**

- *ničelna domneva*  $H_0$  (želimo jo ovreči - lahko je (ne)parametrična, enostavna/sestavljena)
- *alternativna domneva*  $H_a$  ali  $H_1$  (nazdružljiva z ničelno, v primeru enostavne parametrične domneve imamo zanjo tri možnosti - katere?)
- *zavrnilni kriterij* (odvisen od stopnje tveganja  $\alpha$ )
- *kritično območje* označimo s  $K_\alpha$
- (13.1) Ilustrativni primer (sodišče)
- Osnovne definicije
  - $P$ -vrednost (bistvena stopnja značilnosti/signifikantnosti, tj. največji  $\alpha$ , ki ga je vodja eksperimenta pripravljen sprejeti glede na dan vzorec,
  - če je  $P\text{-vrednost} > \alpha \rightarrow \text{FTR } H_0$ , tj. ne moremo zavrniti ničelne domneve, če pa je  $P\text{-vrednost} < \alpha \rightarrow \text{zavrni } H_0$ )
  - *napaka 1. vrste* (zavrnitev ničelne domneve, če je le-ta pravilna - njena verjetnost je  $\alpha$ )
  - *napaka 2. vrste* (nismo zavrnili ničelne domneve, čeprav je bila le-ta v resnici napačna - verjetnost tega dogodka označimo z  $\beta$ )
  - *moč testa*  $1-\beta$  (verjetnost zavrnitve ničelne domneve, ko je le-ta v resnici napačna)
- (13.6) Formalen postopek za preverjanje domnev;
- (13.7) Domneve za povprečje (znan odklon, neznan odklon in velik vzorec);
- (13.8) Domneve za razliko dveh povprečij
- (13.9) Domneve za povprečje razlik
- (13.10) Domneve za delež
- (13.11) Razlika deležev dveh populacij
- (13.12) Analiza variance (preverjanje domneve o varianci populacije in preverjanje domneve o kvocijentu varianc in neodvisnih vzorcih)
- (13.13) Domneve o porazdelitvi spremenljivke (enakomerna in normalna).

(14. poglavje) **Bivariatna analiza:**

- (14.1) Povezanost dveh nominalnih spremenljivk
- (14.2) Koeficient asociacije
- (14.3) Povezanost dveh ordinalnih spremenljivk
- (14.4) Povezanost dveh številskih spremenljivk
- (spustili: (14.5) Parcialna korelacija)
- (14.7) Regresijska analiza (linearni model)
- statistično sklepanje o regresijskem koeficientu, pojasnjena varianca (ANOVA)

(15. poglavje) **Časovne vrste in trendi:**

- (15.1) Primerljivost členov v časovni vrsti
- (15.2) Grafični prikaz časovne vrste
- (15.3) Indeksi
- (15.4) Sestavine dinamike v časovnih vrstah

(16. poglavje) **Načrtovanje eksperimentov**

**Zaključki:**

- multivariantna analiza
- diskriminacijska analiza
- analiza faktorjev
- naključni sprehodi
- vizualizacija in analiza slik
- ponovno vzorčenje
- kvaliteta podatkov
- inovacija
- komunikacija
- timsko delo