# SODOBNE NERELACIJSKE PODATKOVNE BAZE (NOSQL)

## **Vsebina**

- problemi relacijskih podatkovnih baz
- nerelacijske podatkovne baze, NoSQL
- MongoDB
  - namestitev
  - delo z dokumenti
  - iskanje
  - posodabljanje
  - vgnezdeni dokumenti
  - kurzorji
  - indeksiranje

## **Uvod**

"Facebook now has more than 1.35 billion monthly active users. Its data storage is more than 300 petabytes. Every 60 seconds on Facebook:

- 510 comments are posted
- 293,000 statuses are updated
- 136,000 photos are uploaded" (Okt 2014)

"Twitter now has more than 300 million active users, sending > 600 million tweets every day" (Jan 2015)

#### "Webscale" aplikacije

- veliko podatkov
- veliko istočasnih uporabnikov
- veliko zahtevanih obdelav
- časovno pogojene obremenitve
- so relacijske baze dovolj?





## Možne rešitve

- vertikalno skaliranje (scaling up): nadgradnja virov z zmogljivejšimi
  - kje je meja? cena?
- horizontalno skaliranje (scaling out): porazdelitev podatkov po več strežnikih
  - master-slave: pisanje se izvaja na glavnem strežniku, branja se lahko izvajajo iz sekundarnih baz (problem - konsistentnost)
  - deljenje podatkov (partitioning, sharding): razdelitev podatkov v podmnožice, boljše skaliranje, vendar izguba možnosti izvedbe stikov med podatki in referenčne integritete

#### druge možne rešitve

- replikacija cele baze v več "master" baz,
- izvedba brez stikov denormalizacija,
- hranjenje majhnih baz v primarnem spominu,
- NoSQL...

# Primer problema...

evidenca izposojenih knjig

<u>vpisna</u>	ime	letnik	knjiga
63960001	Darko	2	Wirth
63960002	Mitja	3	null
63960003	Ana	1	null
63960004	Laura	2	Sedgewick
63960005	Matej	2	null
63960006	Vera	1	null

- kaj, če želimo hraniti več izposojenih knjig za študenta in podatke o letnikih?
  - sprememba sheme?

<u>vpisna</u>	ime	letnik
63960001	Darko	2
63960002	Mitja	3
63960003	Ana	1
63960004	Laura	2
63960005	Matej	2
63960006	Vera	1

<u>vpisna</u>	knjiga	
63960001	Wirth	
63960004	Sedgewick	
63960004	Wirth	

<u>vpisna</u>	vpis
1	4231
2	3523
3	3291

# Primer problema...

- iskanje potrebuje stikanje tabel (join)
  - SELECT knjiga
     FROM studenti, knjige
     WHERE studenti.vpisna=knjige.vpisna
     AND studenti.ime="Mitja"
- definicija stika v relacijski algebri?

$$R \bowtie_{\theta} S = \sigma_{\theta}(R \times S)$$

- težave:
  - počasnost pri veliki količini podatkov
  - slabe zmožnosti porazdeljevanja podatkov
- druge možne težave pri uporabi relacijskih baz:
  - prekompleksen in neobvladljiv model
  - veliko začasnih podatkov, ki niso povezani z glavnimi (vsebine nakupovalnih vozičkov, ...)
  - normalna oblika upočasnjuje procesiranje podatkov (denormalizacija)
  - veliko binarnih objektov
  - uporabljamo transakcije, katerih trajnost ni pomembna (všečkanje na FB)

# NoSql



- relacijske baze: one size fits all
  - ACID (atomicity, consistency, isolation, durability),
- nerelacijske baze: prilagojena podatkovna skladišča za različne aplikacij
  - žrtvujejo shemo ACID
  - shema BASE (basically available, soft state, eventually consistent)
  - prednosti: cena, zmogljivost
  - slabosti: pomanjkanje standardov, potrebna specifična priučitev, omejena prenosljivost, nezrelost tehnologije
  - ne uporabljajo fiksne podatkovne sheme in stikov!



## **Izvedbe NoSQL**

- prilagojene določenim vrstam aplikacij
  - **shrambe s ključi (key-value pairs):** BerkleyDB, Keyspace, Dynomite, Voldemort, MemcachedDB in Tokyo Cabinet.
  - dokumentne zbirke: MongoDB (Foursquare, SourceForge, Fotopedia, Joomla Ads), CouchDB (CERN, BBC), Redis
  - zbirke grafov: Neo4j, AllegroGraph, InfoGrid, Sones, graphDB in FlockDB
  - stolpično usmerjene zbirke (column-oriented databases): Hypertable in Cassandra (Digg, Facebook, Twitter, Rackspace),
  - objektne shrambe: Oracle Coherence, db4o, ObjectStore, GemStone, Polar









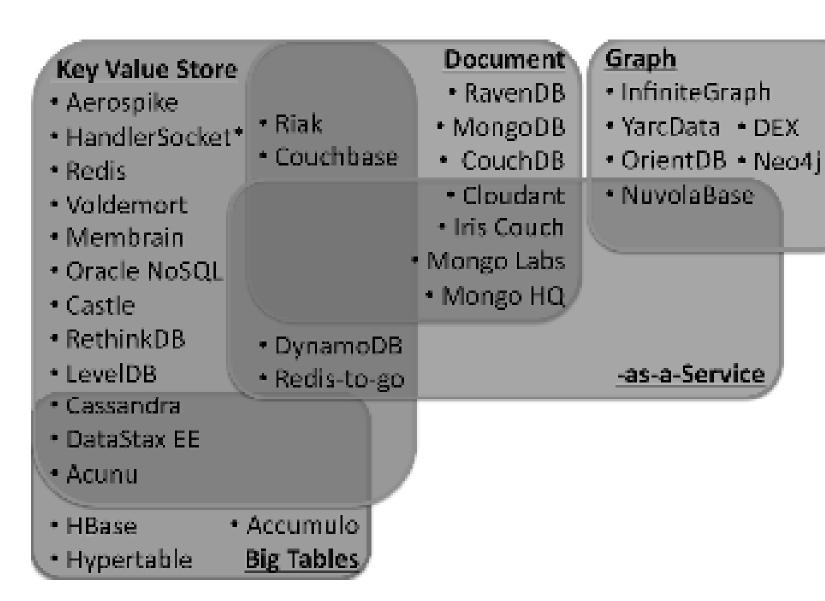






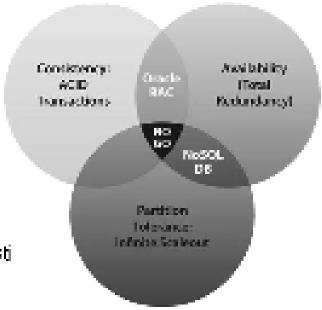


# **NoSQL SUPB**



## **Teorem CAP**

- Eric Brewer, 2000; dokaz na MIT 2002
- sistem za delo s podatki ima tri lastnosti: konsistentnost (Consistency), razpoložljivost (Availability) in zmožnost delitve podatkov (Partitions)
- Teorem pravi: pri deljenju podatkov lahko optimiziramo **največ dve** od teh treh lastnoឡា



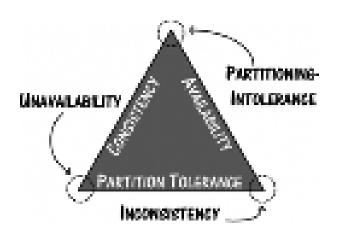
Primer: podatke razdelimo na več računalnikov. Kasnejša posodobitev podatka zahteva posodobitev vseh kopij. Scenarija:

- zaklenemo vse kopije, da zagotovimo konsistentnost (zmanjšana razpoložljivost),
   ali
- žrtvujemo konsistentnost na račun večje razpoložljivosti

## **Teorem CAP**

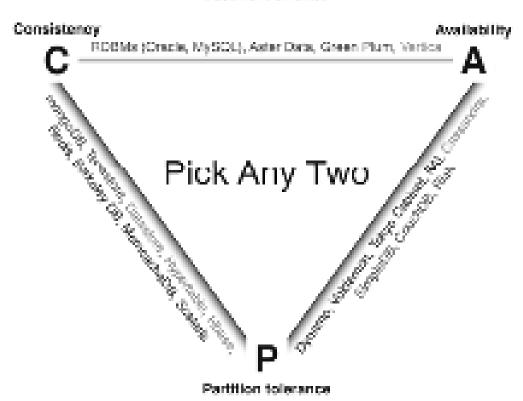
Torej: žrtvovati je potrebno enega od kriterijev: C, A ali P

- konsistentni in razpoložljivi (CA) sistemi imajo težavo z deljenjem podatkov, težave običajno obvladujejo z replikacijo,
- konsistentni, porazdeljeni sistemi (CP) imajo težavo z razpoložljivostjo podatkov ob naporu zagotavljanja njihove konsistentnosti,
- razpoložljivi, porazdeljeni sistemi (AP) dosegajo sčasno konsistentnost (eventual consistentcy) z replikacijo podatkov in občasnim preverjanjem konsistentnosti v podatkovnih vozliščih.



## **Teorem CAP**





# **Težave NoSQL**

- Ni standardnega povpraševalnega jezika
  - Sami delamo, kar sicer dela SQL prevajalnik (nizkonivojske operacije)
- Zavržemo 30 let izkušenj relacijskih SUPB
  - Težko smo boljši od prevajalnika
  - Visokonivojski jeziki so boljši po več kriterijih (neodvisnost od podatkov, manj kode)
- Ni shranjenih podprogramov
  - samo ena interakcija med aplikacijo in SUPB (namesto ena za vsak zapis, kot pri NoSQL)
  - premaknemo kodo k podatkom in ne obratno
- Če ACID danes ne potrebujemo, ali lahko zagotovimo to za jutri?
  - premiki podatkov, nekomutativne posodobitve, večzapisna stanja
  - če potrebujemo integritetne omejitve
  - eventuelna konsistentnost → zmeda v podatkih

# Za kaj je torej dober NoSQL

- Netransakcijski sistemi
- Enozapisne, komutativne transakcije
- Neprimerno za sodobne OLTP sisteme
- Ne potrebujemo enovitega povpraševalnega jezika
  - programska koda
  - CQL, UnQL (po zgledu SQL, nestandardno, nekompatibilno)

# SQL + NoSQL = NewSQL?

#### NoSQL:

- Nova, moderna zvrst nerelacijskih SUPB
- Zavračanje pojmov fiksnih shem tabel in stičnih operacij
- Načrtovan z namenom omogočanja zahtev po masivnem horizontalnem skaliranju
- Omogoča upravljanje podatkov brez definirane sheme
- Bye, bye, SQL

#### NewSQL

- Zadnji trend na področju relacijskih SUPB
- Ohranja SQL in ACID
- Načrtovan z namenom omogočanja zahtev po masivnem horizontalnem skaliranju ali
- Tako velik performančni napredek, da horizontalno skaliranje ni več potrebno

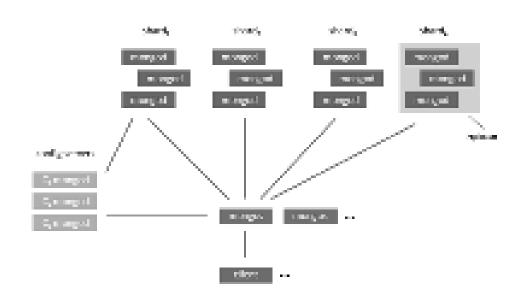
# **NewSQL SUPB**

-as-a-Service - StormDB - Xeround	Datomic     Akiban	MemSQL     Drizzle     VoltDB	New databases  • NuoDB  • SQLFire
Tokutek	Akiban	• JustOneDB	Translattice
	GenieDB		Clustrix
			• SchoonerSQL
	ScaleDB	ParElastic	ScaleBase
Storage engines	<ul> <li>MySQL Cluster</li> </ul>	<ul> <li>Continuent</li> </ul>	• ScaleArc
	Zimory Scale	• Galera	CodeFutures
		Clus	stering/sharding

- problem relacijskh baz
- nerelacijske podatkovne baze, NoSQL
- MongoDB
  - namestitev
  - delo z dokumenti
  - iskanje
  - posodabljanje
  - vgnezdeni dokumenti
  - kurzorji
  - indeksiranje

# **MongoDB**

- dokumentno-usmerjena podatkovna baza (JSON/BSON)
- lasten komunikacijski protokol, ki uporablja TCP/IP
- konzola uporablja JavaScript sintakso
- podatkovna baza -> zbirke dokumentov (Collections) -> dokumenti (Documents)
- replikacija v obliki master-slave, delitev podatkov (sharding)
- napisan v C++
- sistem ne uporablja stikov podatkov (vendar možni v uporabniškem programu)
- podatkovni tipi: null, boolean, 32-bit integer, 64-bit integer, 64-bit floating point, string



- polna postavitev sistema:
  - mongod strežnik podatkov
  - mongos usmerjevalnik k podmnožici podatkov
  - strežniki so lahko replicirani (redundantnost)
  - ločena konfiguracija od podatkov (konfiguracijski strežniki)

## **Namestitev**

- <a href="http://www.mongodb.org/">http://www.mongodb.org/</a>, prenos 32/64-bitne različice
- mongod strežniški program
  - pot do podatkov: argument --dbpath ali uporaba konfiguracijske datoteke in --config
  - strežnik posluša na vratih 27017
  - (spletni administrativni strežnik posluša na vratih 28017)
- mongod strežniški program
- mongo priložen odjemalec (ukazna vrstica)
- pogosta uporaba JavaScript sintakse (specifikacija dokumentov, poizvedb, skripte, ...)

#### > mongod --config mongodb.config

Mon Nov 05 16:20:46 [initandlisten] MongoDB starting : pid=8384 port=27017 dbpath=c:\mongodb\data 64-bit host=quaddrix

Mon Nov 05 16:20:46 [initandlisten] db version v2.2.0, pdfile version 4.5

Mon Nov 05 16:20:46 [initandlisten] git version: f5e83eae9cfbec7fb7a071321928f00d1b0c5207

Mon Nov 05 16:20:46 [initandlisten] build info: windows sys.getwindowsversion(major=6, minor=1, build=7601, platform=2, service pack='Service Pack 1') BOOST LIB VERSION=1 49

Mon Nov 05 16:20:46 [initandlisten] options: { config: "mongodb.config", dbpath: "c:\mongodb\data" }

Mon Nov 05 16:20:46 [initandlisten] journal dir=c:/mongodb/data/journal

Mon Nov 05 16:20:46 [initandlisten] recover : no journal files present, no recovery needed

Mon Nov 05 16:20:46 [initandlisten] waiting for connections on port 27017

Mon Nov 05 16:20:47 [websvr] admin web console waiting for connections on port 28017

# Primerjava pojmov

SQL	MongoDB
database (podatkovna baza)	database (podatkovna baza)
table (tabela)	collection (zbirka)
row (vrstica)	dokument JSON
column (stolpec)	JSON field (polje v dokumentu JSON)
primary key (primarni ključ)	polje _id v dokumentu JSON
indeks	indeks
group by	agregacija

# Primarni ključ dokumenta: \_id

- Striktneje: ekvivalent primarnega ključa
- Imeti mora enolično določeno vrednost
- Lahko je poljubnega tipa
- Lahko ga podamo pri kreiranju dokumenta
- Če ga ne podamo, ga MongoDB kreira avtomatsko v obliki ObjectId
- ObjectId:
  - 12-bytni BSON (binarni JSON) zapis



## Prvi koraki

```
show dbs
show collections
use <podatkovna_baza>
db

db.help()
db.stats()
db.version()
```

 lena izvedba: ustvarjanje baz in zbirk je implicitno ob ustvarjanju dokumentov

```
// seznam baz podatkov
// seznam zbirk
// uporabi podano bazo
// referenca do aktivne baze
// pomoč
// statistike
// različica
                                           document
                             collection
                database
                             collection
  MongoDB
                             collection
                database
```

## **Delo z dokumenti**

## Iskanje - modifikatorji



```
db.x.find({visina: {$gte: 180}})
                                                        // višina večja od 180
                                                        // podobno $1t, $1te, $gte
db.x.find({prijatelji: {$ne: "Bo"}})
                                                        // prijatelj ni enak "Bo"
db.x.find({teza: {$in: [70, 75]}})
                                                        // teža je v podani množici
db.x.find({teza: {$nin: [70, 75]}})
                                                        // teža ni v podani množici
db.x.find({$or: [{teza: {$gt: 80}},
          {visina: {$gt: 180}}]})
                                                        // disjunkcija
                                                        // teža ni deljiva s 5
db.x.find({teza: {$not : {$mod: [5,0]}}})
db.x.find({prijatelji: {$all: ["Bo", "Theodore"]}})
                                                        // vsebovanost podmn.
db.x.find({prijatelji: {$size: 3}})
                                                        // velikost polja je 3
db.x.find({}, {prijatelji: {$slice: [0,2]}})
                                                        // izberi rezino polja
db.x.find({polje : {$exists : 1}})
                                                        // izberi, če polje obstaja
```

## Posodabljanje



```
db.x.update({ime: "Eva"}, {novi dokument})
                                     // zamenjaj cel dokument
db.x.update({ime: "Eva"}, {$set : {mama : "Ana"}})
                                                   // nastavi polje
db.x.update({ime: "Eva"}, {$unset : {mama : 1}})  // odstrani polje
db.x.update({ime: "Eva"}, {$inc : {starost : 5}})
                                                // inkrement polja
db.x.update({ime: "Eva"}, {$push : {prijatelji : "John"}})  // dodaj v polje
db.x.update({ime: "Eva"}, {$addToSet : {loto : 42}}) // dodaj brez ponav.
db.x.update({ime: "Eva"}, {$pop : {loto : 1}})
                                                  // odstrani s konca
db.x.update({ime: "Eva"}, {$pop : {loto : -1}}) // odstrani z začetka
db.x.update({ime: "Eva"}, {$pull : {loto : 15}})
                                                   // odstrani iz polja
db.x.update({ime: "Eva"}, {$inc : {starost : 5}}, true, true) // posodobi vse zadetke
```

## Vgnezdeni dokumenti

možno gnezdenje dokumentov in iskanje po gnezdenih poljih (npr. knjige.avtorjev)

```
doc = { ime : "Janko",
                                 priimek: "Novak",
                                 knjige : [
                                           { avtorjev : 3, strani : 100},
                                           { avtorjev : 5, strani : 50},
                                           { avtoriev : 8, strani : 400}
// iskanje z identično vsebino
db.primer.find({ime: {priimek: "Novak", prvo: "Janko"})
// iskanje po poljih
db.primer.find({"ime.prvo": "Janko", "ime.priimek": "Novak"})
// pogoji vezani na vsebino vsakega elementa
db.primer.findOne({knjige: {$elemMatch: {avtorjev : 3, strani : 50 }}})
// pozicijsko iskanje
db.primer.findOne({"knjige.1.strani": 50})
// $ nadomesti pozicijo najdenegaa dokumenta
db.primer.findOne({"knjige.avtorjev" : 3, "knjige.strani": 50 }, {"knjige.$":1})
```

## Literatura

- Osnovna literatura http://docs.mongodb.org/manual
- kratki (referenčni) povzetki: http://www.10gen.com/reference

## Literatura

#### Queries and What They Match

```
{a: 10, b: "hello"} Docs where a is 10, or an array containing the value 10.
{a: 10, b: "hello"} Docs where a is 10 and b is "hello."

{a: {$q: 10}} Docs where a is greater than 10. Also $1t. (-), $qtc. (>-), $1tc. (-), and $nc. (!-).

{a: {$in: [10, "hello"]}} Docs where a is either 10 or "hello."

{a: {$all: [10, "hello"]]} Docs where a is an erroy containing both 10 and "hello".

{"a.b": | 10} Docs where a is an embedded document with b equal to 10.

{a: {$clicnMatch: (b: 1, c: 2)}} Docs where a is an erroy containing a single item with both b equal to 1 and c equal to 2.

{$ar: [{a: 1}, {b: 2}]} Docs where a is 1 or b is 2.

db.foo.find({a: /*a/}) Docs where a begins with the letter "m".
```

The following queries cannot use indexes as of MongoDB v2.0. These query forms should normally be accompanied by at least one other query term which does use an index:

```
{a: {$aia: [30, "hello"]}} Does where a is anything but 10 or "hello."

(a: {$aod: [10, 1]}) Does where a mod 10 is 1.

{a: {$size: 3}} Does where a is an array with exactly 3 elements.

{a: {$cxists: true}} Does containing an a field.

{a: {$cype: 2}} Does where a is a string (see bacorapectorg for more types).

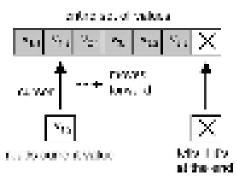
{a: {foo."ban/} Does where a matches the regular expression "foo."bar".

{a: {$not: {$type: 2}}} Does where a is not a string. Snot negates any of the other query operators.
```

## Literatura

```
----- SQL MongoDB ----- ---
     SHIFT * 1908 mers 19000 age to 20 alconters find (Inger (Vites 40))
    SOLDET * FROM users WHERE more LINE | db.users.ffind([same: /los/]);
**Clos.6.**
    SELECT * PROPERTY STATE, Manage LLES, discussive.find@mana: /~ice/@
 SHIFCE 7 MORE moves MARKE age a 30 MAR - allowances. Find (Lagra (Ngl) - 01, 31th - 01(f))
 SELECT Y HERM sterry DEDUC By name that - db.usters. find ().mart@finane: -150
 SELECT \forall being under small age \alpha at any discussors. This ((age: A1, name: "Act")) where \alpha (Cat)
    SELECT * FROM Upons LIMIT 18 SKIP 20 db.usrara.ffind@usblockm.ffinfofun
   55 50 ° FROM users WERF ope - 35 00 - characts dist([Sort]] age (55), [source "Sobil] []]
              ClarChaift, eracu.db 1. TDGD cracus MindOne()
         SCLEET RESTRICT NAME FROM upons - db.users.distinct("name").
                SELECT COUNT(5) FROM users — db.users.count().
        SELECT CREATON) FROM macro SMSRS — obversors disabilitation (Squar S0(1) account()) A60 > 30
             SH RCT CRIST(ADF) FROM users - discovers. Limit(Jupe (Section) transf().comm())
        CREATE TMPS DA norma (name 450) - discovers consumidantes (passes 1))
    CRIATI DEED ON opens (name ASC, age db.users.ensureledes(formed 1, age: -1))
       DOUADA SCIDET * FROM uners WHERE | db.users.ffind(Face: XII).coplete(f)
         UMUNIA notes tall age = 27 MILES | db.userre.update(dpaner: "ack"), (doet: (age: some - "Soh" | 3511, false, trac)
WENT mass. At name a masse . 2 feets - thomses apainted frame. "Sale"), (time frames. Sole" - "Sole", (time)
    Mathematical record services are a "mob" discussive responsible and "mob" b)
```

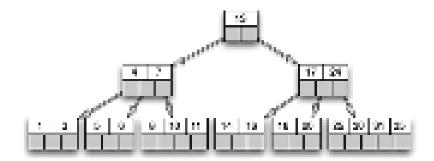
# Kurzorji



kurzor - oblika iteratorja po podatkih v zbirki

- limit, skip, sort
- limit in skip uporabna za ostranjevanje (pagination) v aplikacijah)

## Indeksiranje



- omejitev: največ 64 indeksov na zbirko
- indeks na {a : 1, b : 1, c : 1, ..., z : 1} pohitri delovanje poizvedb
  - enostaven indeks: {a : 1}, sestavljen indeks: {a : 1, b: -1}
  - kaj pomeni številka: 1 naraščajoč, -1 padajoč vrstni red v indeksu
- možno tudi indeksiranje gnezdenih dokumentov

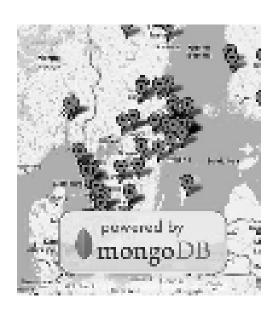
# Geoprostorsko indeksiranje

- iskanje točk, ki so po lokaciji (koordinatah) sorodne izvorni točki
- vsak dokument vsebuje en par podatkov, ki predstavljajo lokacijo; pozor če delamo iz Pythona: Pythonovi slovarji niso urejeni (uporabimo bson.SON())
- koordinate so običajno na intervalu od -180 do 180 (ustreza zemljepisni dolžini/širini)

```
{ "gps" : [ 0, 100 ] }
{ "gps" : { "x" : -30, "y" : 30 } }
{ "gps" : { "latitude" : -180, "longitude" : 180 }}
```

izgradnja indeksa

```
db.map.ensureIndex({"gps" : "2d"})
```

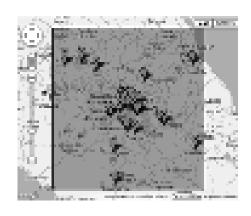


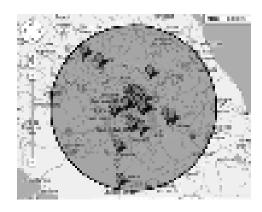
## Geoprostorsko indeksiranje

iskanje:

```
db.map.find({"gps" : {$near : [40, -73]}})
db.map.find({"gps" : {$within : {$box : [[10, 20], [15, 30]]}}))
db.map.find({"gps" : {$within : {$center : [[12, 25], 5]}}))
```

kot oblika možni tudi \$center, \$circle ali \$poly







- možna kombinacija indeksov za optimicijo iskanja po različnih poljih
  - db.places.ensureIndex( { location : "2d" , category : 1 } );
  - db.places.find( { location : { \$near : [50,50] }, category : 'coffee' } );
- tipi indeksov: 2d ravninska geometrija, 2dsphere sferična geometrija (WGS84, World Geodetic System, 1984; uporablja GPS)

# Kompleksne poizvedbe

- element \$where
- pozor: počasna izvedba (pretvorba iz BSON v JavaScript, dela brez uporabe indeksov)

```
> db.primer.insert({jabolko: 1, banana: 6, breskev: 3})
> db.primer.insert({jabolko: 8, ananas: 4, lubenica: 4})
> db.primer.findOne({$where: function () {
... for (var prvi in this) {
     for (var drugi in this) {
        if (prvi != drugi && this[prvi] == this[drugi]) return true;
... return false;
... }})
     "_id": ObjectId("5098b267b6979a0c0c662391"),
     "jabolko": 8,
     "ananas": 4,
     "lubenica": 4
```

# PyMongo – MongoDB odjemalec

- Instalacija v Python: pip install pymongo
- Alternativa:
  - Prenesite https://github.com/mongodb/mongo-python-driver
  - Odpakirajte in zaženite: python setup.py install
- Navodila: http://api.mongodb.org/python/current/tutorial.html
- Zdaj lahko iz Pythona dostopate tako do MariaDB, kot MongoDB

## **Uporaba v Pythonu**

- knjižnica pymongo
- zapis funkcij s podčrtaji (find\_one namesto findOne ipd.)
- slovarji ali BSON namesto JSON

```
from pymongo import Connection

connection = Connection('localhost', 27017)  # privzeti parametri
db = connection.test
db.collection_names()  # seznam vseh zbirk

db.obvestila.insert(dokument)  # dodajanje dokumenta

posts.find_one({})

for post in db.izpiti.find({}):  # iteriranje po zadetkih
    post

for post in db.izpiti.find({}):  # varnejše iteriranje
    print(post.get("nagrada", "ni nagrade"))
```

#### Iskanje, posodabljanje

```
# štetje zapisov - count
db.izpiti.find({"letnik": 1}).count()

# omejitev števila zadetkov - limit
for x in db.izpiti.find({"letnik": 1}).limit(3): x

# uporaba modifikatorjev, sortiranje
for x in db.izpiti.find({"letnik": {"$gt": 1}}).sort("ime"): x

# posodabljanje zapisov
db.izpiti.update({"letnik": 1},{"$inc": {"letnik": 1}})  # samo prvi
db.izpiti.update({"letnik": 1},{"$inc": {"letnik": 1}}, multi=True) # vseh zadetkov
db.izpiti.update({"letnik": 1},{"$inc": {"letnik": 1}}, upsert=True) # ustvari, če ne obstaja
```

## Indeksi: navadni in geo

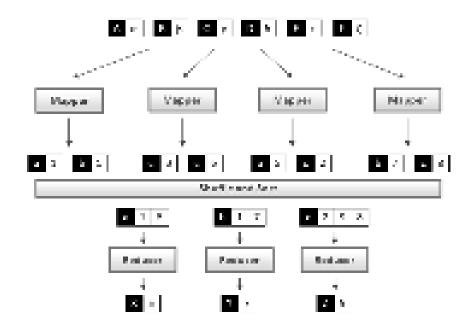
```
#indeksiranje
db.izpiti.create index([("letnik", ASCENDING), ("author", ASCENDING)])
db.izpiti.drop index([("letnik", ASCENDING), ("author", ASCENDING)])
db.izpiti.find({...}).explain()["cursor"] # statistike iskanja
db.izpiti.find({...}).explain()["nscanned"]
# geoprostorsko indeksiranje
import bson
from pymongo import GEO2D
                                               # sinonim za "2dsphere"
loc = bson.SON()
                                                # ohranja vrstni red elementov
loc["x"]=3
loc["y"]=4
dok = {"ime": "Metka", "loc": loc}
db.prostor.insert(dok)
db.prostor.create index([("loc", GEO2D)])
for doc in db.prostor.find({"loc": {"$near": [3, 6]}}).limit(3): doc
for doc in db.prostor.find({"loc": {"$within": {"$box": [[0,0],[3,4]]}}}): doc
```

# Primer (jadralci)

```
# Jadralec Darko
db.jadralec.insert( {"jid": 22, "ime" : "Darko", "rating": 10, "starost":45} )
# Darkove rezervacije
db.rezervacija.insert( {"jid": 22, "cid" : 101, "dan": "2006-10-10" } )
db.rezervacija.insert( {"jid": 22, "cid" : 102, "dan": "2006-10-10" } )
db.rezervacija.insert( {"jid": 22, "cid" : 103, "dan": "2006-10-8" } )
db.rezervacija.insert( {"jid": 22, "cid" : 104, "dan": "2006-10-7" } )
# Indeksi
db.rezervacija.ensure index("jid")
db.rezervacija.ensure index("cid")
("cid", pymongo.ASCENDING)])
# STIK: Poišči vse Darkove rezervacije
darko = db.jadralec.find one({"ime" : "Darko"})
rez = db.rezervacija.find( {"jid" : darko["jid"]} )
for r in rez:
   print r
```

#### **MapReduce**

- podoben pristop kot pri funkcijskem programiranju
- omogoča paralelizacijo poizvedb v velikih podatkovnih bazah preko velikega števila računalnikov/jeder/procesorjev
- prepočasen za izvajanje v realnem času
- map: preslika vhodne dokumente v drugačno predstavitev in jo posreduje s stavkom emit
- reduce: za vsak ključ prejme polje vrednosti od funkcije map in izračuna končni rezultat



#### **MapReduce**

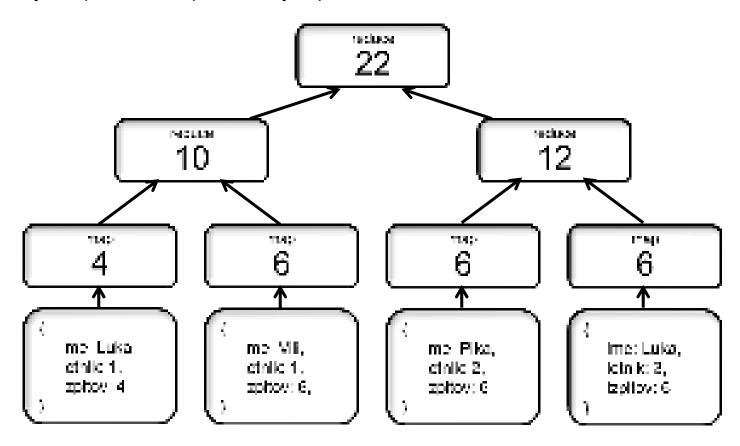
Podana je študentska evidenca opravljenih izpitov:

```
> db.izpiti.find({},{_id:0})  # Projekcija, izpis brez _id
{ "ime" : "Luka", "letnik" : 1, "izpitov" : 4 }
{ "ime" : "Vili", "letnik" : 1, "izpitov" : 6 }
{ "ime" : "Jaka", "letnik" : 1, "izpitov" : 2 }
{ "ime" : "Taja", "letnik" : 2, "izpitov" : 2 }
{ "ime" : "Dino", "letnik" : 2, "izpitov" : 4 }
{ "ime" : "Igor", "letnik" : 3, "izpitov" : 2 }
{ "ime" : "Nina", "letnik" : 3, "izpitov" : 3 }
{ "ime" : "Dani", "letnik" : 3, "izpitov" : 5 }
{ "ime" : "Dasa", "letnik" : 3, "izpitov" : 5 }
```

#### Zanima nas:

- Kakšno je skupno število izpitov, ki so jih opravili vsi študenti v letnikih?
- Kakšno je povprečno število izpitov, ki so jih opravili vsi študenti v letnikih?
- Kakšno je povprečno število izpitov, ki so jih opravili študenti po posameznih letnikih?

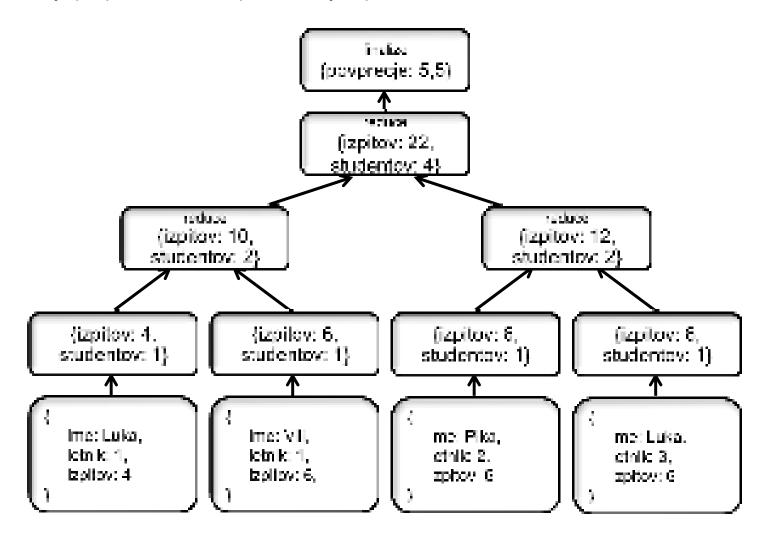
1.) Kakšno je skupno število izpitov, ki so jih opravili vsi študenti v letnikih?



- reduce mora biti asociativen, vrstni red izvedbe je neopredeljen
- reduce mora vrniti podatek istega tipa kot je tip rezultata funkcije emit

```
var mapper = function() {
     emit(null, this.izpitov)
var reducer = function(key, values) {
     var sum = 0;
     values.forEach(function(x) {
          sum += x;
     return sum;
> db.izpiti.mapReduce(mapper, reducer, {out: "rezultati"})
        "result": "rezultati",
        "timeMillis" : 97,
        "counts" : {
                                                                  naziv zbirke, v
                "input" : 10,
                                                                    kateri se bo
                "emit" : 10,
                                                                  shranil rezultat
                "reduce": 1,
                "output" : 1
       },
"ok" : 1,
                                       izpis rezultata
> db.rezultati.find()
{ "_id" : null, "value" : 39 }
> db.rezultati.findOne().value
39
```

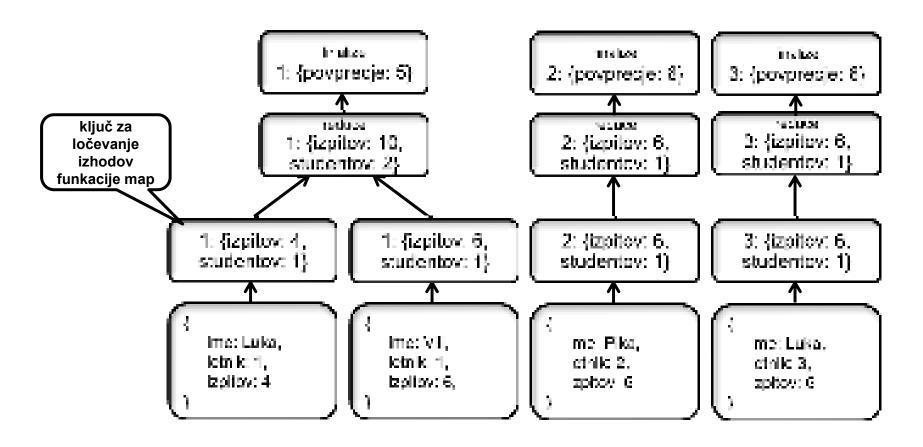
2.) Kakšno je povprečno število izpitov, ki so jih opravili vsi študenti v letnikih?



Kakšno je povprečno število izpitov, ki so jih opravili vsi študenti v letnikih?

```
var mapper = function() {
     emit(null, {studentov: 1, izpitov: this.izpitov})
var reducer = function(key, values) {
     var sum = {studentov: 0, izpitov: 0}
     values.forEach(function(x) {
          sum.studentov += x.studentov;
          sum.izpitov += x.izpitov
     })
     return sum;
> db.izpiti.mapReduce(mapper, reducer, {out: "rezultati"})
> db.rezultati.find()
                                                                            funkcija za
{ " id" : null, "value" : { "studentov" : 10, "izpitov" : 39 } }
                                                                            finalizacijo
> var finalizer = function(key, value) {
                                                                          rezultata, ki se
     var povprecje = value.izpitov/value.studentov;
                                                                              izvede
     delete value.izpitov;
     delete value.studentov;
     value.povprecje = povprecje;
     return value;
}
                                                                        dodatni parameter
> db.izpiti.mapReduce(mapper, reducer,
                                                                            za uporabo
       {out: "rezultati", finalize: finalizer})
                                                                           finalizatoria
> db.rezultati.find()
{ " id" : null, "value" : { "povprecje" : 3.9 } }
```

- 3.) Kakšno je povprečno število izpitov, ki so jih opravili študenti po posameznih letnikih?
  - emit(key, value)



Kakšno je povprečno število izpitov, ki so jih opravili študenti po posameznih letnikih?

```
var mapper = function () {
    emit(this.letnik, { studentov: 1, izpitov: this.izpitov })
% reducer in finalizer ostaneta enaka!
                                                                             uporaba ključa
> db.izpiti.mapReduce(mapper, reducer,
             { out: {inline: 1}, finalize: finalizer }).results
                            " id" : 1,
                            "\overline{v}alue" : {
                                                                            izpis na konzolo
                                     "povprecje" : 4
                   },
{
                           "_id" : 2,
"value" : {
                                     "povprecie": 3
                   },
{
                            " id" : 3,
                            "\overline{v}alue" : {
                                     "povprecje": 4.2
```

## PyMongo in map\_reduce

```
objekt za hranjenje
                                         programske kode
from bson.code import Code
map = Code("function() {"
                 "emit(this.letnik, {studentov: 1, izpitov: this.izpitov})"
                                                                     zapis programske
reduce = Code("function(key, values) {"
                                                                     kode v več vrsticah
                 "var sum = {studentov: 0, izpitov: 0};"
                 "values.forEach(function(x) {"
                      "sum.studentov += x.studentov;"
                      "sum.izpitov += x.izpitov;"
                 "});"
                 "return sum;"
                                                                   zbirka, kamor se
               "}")
                                                                    zapiše rezultat
result = db.izpiti.map reduce(map, reduce, "myresults")
for doc in result.find():
    print doc
                                        kurzor po
                                        rezultatih
```

#### Literatura



- Eelco Plugge, Tim Hawkins, Peter Membrey: The Definitive Guide to MongoDB: The NoSQL Database for Cloud and Desktop Computing. Apress, 2010.
- Karl Seguin: The Little MongoDB Book. <a href="http://github.com/karlseguin/the-little-mongodb-book">http://github.com/karlseguin/the-little-mongodb-book</a>, 2012.
- MongoDB manual: <a href="http://www.mongodb.org/display/DOCS/Manual">http://www.mongodb.org/display/DOCS/Manual</a>
- PyMongo 2.3 Documentation: <a href="http://api.mongodb.org/python/current/">http://api.mongodb.org/python/current/</a>